



PROIECT

CANCERUL PULMONAR

Studenți:

Floriceș Luca-Bogdan

Horceag Miruna-Cristina

Strat Ana-Maria

Grupa: 1435



Cuprins

1.Introducere.....	3
2.State of the art	7
3.Imbunatatirea imaginilor	13
4. Rezultate obtinute.....	40
Concluzii.....	44
Bibliografie	45

1.Introducere

Afectiunea aleasa este cancerul pulmonar. Cancerul pulmonar reprezintă o afecțiune malignă caracterizată printr-o multiplicare necontrolată a celulelor epiteliale ale țesutului pulmonar, la nivelul unui plămân sau al ambilor plămâni, la nivelul bronhiilor sau al alveolelor pulmonare. Netratată, această multiplicare poate evolua cu dezvoltarea unei mase tumorale (neoplazie) cu formarea propriei rețele de vase de sânge și limfatice, și poate disemina pe cale hematogenă sau limfatică în țesuturile din apropiere (regionale: la nivelul ganglionilor limfatici) sau al altor organe din corp, la distanță, proces denumit metastazare. Majoritatea tipurilor de cancer care pornesc din plămân sunt carcinoamele derivate din celulele epiteliale. Principalele tipuri de cancer pulmonar sunt carcinomul cu celule mici (cancerul bronho-pulmonar microcelular sau CBPM), supranumit și cancer cu celule „în bob de ovăz”, și carcinomul pulmonar fără celule mici (cancerul bronho-pulmonar non-microcelular sau CBPNM). Cele mai frecvente simptome sunt tusea (inclusiv tusea cu sânge), pierderea în greutate și dificultățile de respirație (dispneea). [\[1\]](#)

Cauza cancerului bronhopulmonar nu este cunoscuta, insa exista mai multi factori de risc asociati cu aparitia tumorilor maligne primare la acest nivel.

Factori de risc

- Fumatul este cauza principala a cancerului pulmonar in peste 80% dintre cazuri. Comparativ cu nefumatorii, fumatorii au un risc de 25 de ori mai mare de a dezvolta cancer pulmonar.
- Dintre persoanele diagnosticate, se estimeaza ca 40% sunt fumatori activi, 45% sunt fosti fumatori, iar 15% nu au fumat niciodata.

- Riscul de a dezvolta cancer pulmonar variaza cu varsta de la care s-a inceput fumatul, perioada de timp in care s-a fumat (durata fumatului) si numarul de tigari fumate (intensitatea fumatului).
- Pentru cei 15% dintre pacienții care nu au fumat, există și alți factori de risc posibili pentru cancerul pulmonar:
- Expunerea la radon: Este a doua cauză de cancer pulmonar după fumat. Radonul este un gaz radioactiv inodor și incolor, produs de uraniul din sol, care devine parte a aerului respirat în locuințe. Locuitorii blocurilor de la parter și cei care locuiesc la casă sunt cei mai expuși. Nivelurile periculoase de radon se pot acumula în orice locuință. Măsurile de prevenție includ ventilarea frecventă a camerelor, folosirea aerului condiționat și etanșarea podelelor pentru a reduce trecerea radonului din sol în locuință.
- Expunerea la azbest și alți agenți cancerigeni inhalabili: Precum praful de lemn, vapori de sudură, arsenic, metale industriale, nichel, beriliu și crom. Cei mai expuși sunt angajații din industria de prelucrare a oțelului, nichelului, cromului și a cărbunelui.
- Poluarea aerului: Atât în medii urbane, cât și industriale.
- Antecedentele familiale de cancer pulmonar
- Vârsta: Persoanele peste 65 de ani sunt mai expuse.
- Dietă săracă în fructe și legume
- Consumul excesiv de alcool
- Boala pulmonară obstructivă cronică (BPOC).
- Fibroza pulmonară (post TBC, infecții pulmonare repetate).
- Cancerul esofagian, la gât sau cap.
- Limfomul sau cancerul mamar, tratate cu radioterapie toracică pulmonară, care uneori poate avea consecințe similare cancerului. [\[2\]](#)

Diagnostic

Cele mai frecvente investigatii care conduc catre diagnostic sunt testele imagistice si biopsia. Cea mai des utilizata metoda este metoda imagistica numita tomografie computerizata.

Tomografia vine de la cuvântul grecesc "tomos" care înseamnă "felie" sau "secțiune" și graphia care înseamnă "scriere".

O scanare tomografică computerizată este o tehnică de imagistică medicală folosită pentru a obține imagini detaliate ale interiorului corpului.

Funcționarea CT se bazează pe două principii:

- măsurarea atenuării unui fascicul de raze X ce traversează un corp și calculul coeficientului sau de atenuare, deci a densității sale radiologice,
- reconstrucția imaginii unui obiect plecând de la proiecțiile sale diferite, practic realizând o reproducere bidimensională a realității tridimensionale. [\[4\]](#)

Planul de secțiune este pentru majoritatea structurilor investigate cel transversal sau axial. Pentru fiecare secțiune tubul de raze X se rotește în jurul pacientului, având pe partea opusă detectorii al căror rol este de a recepta energia fotonică ce a traversat corpul uman și de a o transforma în energie luminoasă, pe care ulterior o fotodiodă o transformă în semnale electrice. Aceste semnale sunt apoi digitalizate și transmise unui procesor de imagini, ce reconstruiește imaginea pe baza unui număr mare de măsurători. Aparatele CT noi au sisteme informatice mai rapide și un software care poate procesa nu numai secțiunile transversale individuale, dar și pe cele în continuă schimbare. Acestea sunt numite aparate CT spirală. [\[4\]](#)

Un computer tomograf nativ nu implică administrarea unei substanțe de contrast, structurile anatomice de interes putând fi vizualizate eficient și fără. Investigatia de computer tomograf cu substanța de contrast presupune administrarea de agenți intravenoși pe baza de iod, care permit mult mai eficient identificarea anumitor patologii. Unul dintre cei mai utilizați agenți de contrast este cel pe baza de iod, cu administrare intravenoasă, permitând vizualizarea mult mai eficientă a structurilor moi vascularizate. Iodul va ajunge prin circulația sanguină la nivelul organului interesant, iar ulterior teritoriul va putea fi mai eficient vizualizat prin tomografie. Rezultatele vor fi mult mai ușor de tradus de către medic și, astfel, se va putea obține o interpretare relevantă a eventualei patologii asociate organului respectiv.

Tehnica de computer tomograf cu substanța de contrast ridică și riscuri asociate substanței ce este folosită în protocolul de investigație. Unele persoane pot dezvolta și reacții alergice la



UNIVERSITATEA POLITEHNICA BUCUREȘTI
Facultatea de Inginerie Medicală



substanta folosita pentru computer tomograf cu substanta de contrast, care includ: ameteli si varsaturi, greata, eruptii cutanate ulterioare, constipatie, crampe abdominale, ingreunarea respiratiei, dureri de cap.

2.State of the art

Tomografia computerizată (CT) este considerată una dintre cele mai bune modalități de imagistică și a devenit modalitatea standard pentru analizarea și evaluarea tumorilor pulmonare. Segmentarea precisă a nodulilor canceroși din imaginile scanărilor CT este foarte importantă, deoarece furnizează informații necesare care sunt strâns asociate cu diagnosticul precoce al cancerului pulmonar și cresc șansele de supraviețuire ale pacienților. Segmentarea automată a tumorilor pulmonare din imaginile scanărilor CT poate ajuta practicienii medicali să ofere un diagnostic precoce pentru monitorizarea ulterioară a progresiei bolii. Metodele clasice de segmentare automată a tumorilor depind în principal de ingineria caracteristicilor, care necesită extragerea caracteristicilor din imaginile de intrare pentru antrenarea ulterioară a clasificatorului.

[\[3\]](#)

Articolul 1 :

S-a dezvoltat un algoritm automatizat de prelucrare a imaginilor pentru segmentarea plămânilor și a tumorilor pulmonare individuale în scanările cu tomografie computerizată micro (micro-CT) în vivo ale modelelor de șoareci cu cancer pulmonar cu celule non-mici și fibroză pulmonară. Peste 3000 de scanări, obținute în cadrul mai multor studii, au fost utilizate pentru a antrena/valida un model de segmentare 3D U-net pentru plămâni și un clasificator cu mașină de vectori suport (SVM) pentru segmentarea tumorilor pulmonare individuale.

Algoritmul de segmentare a plămânilor U-net poate fi folosit pentru a estima modificările în volumul țesutului moale din plămâni (în principal tumori și vase de sânge), în timp ce SVM-ul antrenat este capabil să facă distincția între tumori și vase de sânge și să identifice tumori individuale.

Algoritmii de segmentare antrenați (1) reduc semnificativ timpul necesar pentru segmentarea plămânilor și a tumorilor, (2) reduc tendința de eroare și erorile asociate cu segmentarea manuală a imaginilor și (3) facilitează identificarea tumorilor pulmonare individuale

și evaluarea obiectivă a modificărilor în volumele plămânilor și ale tumorilor individuale în diferite condiții experimentale.

Au fost generate 2305 obiecte de țesut în urma etapelor de preprocesare a imaginilor. Acest proces poate include aplicarea unor tehnici de corecție a artefactelor, filtrare a zgomotului și îmbunătățire a contrastului pentru a pregăti imaginile pentru segmentare.

Obiectele de țesut generate au fost etichetate manual ca fiind „tumor”, „vas” sau „altceva”. În acest caz, 781 de obiecte au fost etichetate ca „tumor”, 1020 ca „vas” și 504 ca „altceva”.

Un clasificator cu mașină de vectori suport (SVM) cu un kernel Gaussian a fost determinat a fi cel mai bun model în ceea ce privește scorul F1 pentru clasificarea obiectelor de tumori. Un SVM este un algoritm de învățare supervizată utilizat pentru clasificare și regresie.

Rezultatele performanței modelului SVM arată un scor F1 de 0.93 pentru setul de antrenament și 0.85 pentru setul de testare. Scorul F1 este o măsură a preciziei și sensibilității unui clasificator.

Alți algoritmi de clasificare au fost, de asemenea, evaluați, cum ar fi metoda de învățare ensemble de clasificare, dar SVM a fost selectat ca model final datorită performanței sale mai bune și a riscului mai mic de suprasolicitare.

Performanța modelelor a fost evaluată folosind scorul F1, care este o metrică comună pentru evaluarea performanței algoritmilor de clasificare. Acesta este calculat ca o medie armonică între precizie și sensibilitate. [\[5\]](#)

Articolul 2:

Acest articol prezintă o prezentare comprehensivă a progreselor recente în tehnici de segmentare semantică, în special în domeniul imagistic medical. De asemenea, investighează eficacitatea diferitelor arhitecturi pentru segmentarea imaginilor medicale și evidențiază beneficiile, provocările și direcțiile viitoare potențiale pentru această tehnologie.

Prima parte a articolului discută o metodă propusă, care folosește o mașină cu vectori suport (SVM) bazată pe metoda matricei tridimensionale pentru segmentarea tumorilor din imagini CT. Această metodă nu a fost capabilă să facă distincția între tumorile benigne și cele maligne. În

contrast, o altă abordare prezentată utilizează tehnica de segmentare a parenchimului pulmonar pentru a extrage nodulii candidați din parenchimul pulmonar segmentat, urmată de clasificarea acestora cu ajutorul unui algoritm de Random Forest (RF).

Articolul descrie apoi o nouă arhitectură de segmentare semantică propusă, care folosește un MobileNetV2 pre-antrenat ca encoder al unui U-Net clasic. Această arhitectură a fost antrenată și ajustată fin pe setul de date obținut din competiția Medical Segmentation Decathlon Challenge (MSD) 2018. Rezultatele obținute au demonstrat o performanță superioară, cu un scor Dice de 0.8793, o acoperire (recall) de 0.8602 și o precizie de 0.93, comparativ cu alte rețele existente.

Setul de date folosit pentru antrenamentul, validarea și evaluarea algoritmului propus a fost obținut din competiția Medical Segmentation Decathlon Challenge (MSD). Acesta constă în 96 de imagini CT subțiri preoperatorii, care au fost împărțite într-un set de antrenament de 64 de imagini CT heterogene, cu ground truth-uri anotate cu precizie. Fiecare volum de scanare CT are dimensiunile $512 \times 512 \times X$, unde X reprezintă variabilitatea dimensiunii voxelului pentru fiecare scanare CT. Setul de date a fost procesat pentru a depăși inconsistentele dimensiunii voxelului prin împărțirea acestora în imagini 2D.

În final, performanța modelului propus a fost validată prin testarea pe un sub-set al setului de date MSD, iar rezultatele obținute au confirmat eficacitatea și precizia acestuia în segmentarea tumorilor pulmonare din imagini CT.

Performanța modelului, validată prin testarea pe un sub-set al setului de date MSD, a demonstrat un scor Dice de 0.8793, o acoperire (recall) de 0.8602 și o precizie de 0.93. [\[6\]](#)

Articolul 3:

Această cercetare introduce o metodă nouă numită Rețea de Atenție Rectificată Multi-Obiect bazată pe Optimizatorul Social Sky Amestecat (SSSO-based MORAN) pentru clasificarea eficientă a bolii de cancer pulmonar. Algoritmul SSSO integrează Algoritmul de Optimizare al Păstorului Amestecat (SSOA) și algoritmul social ski-driver (SSD).

Setul de date Lung Image Database Consortium (LIDC-IDRI) conține scanări tomografice computaționale (CT) toracice pentru analiză și screening al cancerului pulmonar, cu leziuni

interpretate marcate. Setul de date cuprinde 1018 cazuri și este format din colaborarea a șapte corporații educaționale și opt corporații de imagistică medicală.

Performanța de clusterizare a metodei propuse DREFC este evaluată folosind metrici precum acuratețea clusterizării, coeficientul Jaccard și coeficientul Silhouette, iar performanța de clasificare a metodei propuse este analizată luând în considerare măsurile precum sensibilitatea, specificitatea, acuratețea și MAE (Eroarea Medie Absolută).

Procesul începe cu introducerea unei imagini de tomografie computerizată (CT), care este supusă unei prelucrări preliminare folosind filtrarea Gaussiană pentru a îmbunătăți calitatea imaginii. Ulterior, Regiunea de Interes (ROI) este extrasă din imaginea prelucrată. Lobii pulmonari sunt apoi segmentați folosind metoda propusă de clustering fuzzy Deep Renyi entropy (DREFC).

După segmentarea lobilor pulmonari, regiunea nodulului este identificată în interiorul imaginii pulmonare. Clasificarea cancerului este realizată pe baza diferitelor caracteristici extrase din nodulii identificați. Aceste caracteristici includ Modelul XOR Local Gabor (LGXP), caracteristicile Matricei de Co-ocurență a Nivelurilor de Gri (GLCM), Modelul Global Binar (GBP), transformarea Tetrolet și caracteristici statistice.

Algoritmul propus demonstrează o performanță mai mare în ceea ce privește exactitatea, eroarea medie absolută (MAE), sensibilitatea și specificitatea. În mod specific, metricile de performanță raportate sunt o exactitate de 0,896, o MAE de 0,104, o sensibilitate de 0,8969 și o specificitate de 0,845.

În ansamblu, algoritmul SSSO-based MORAN prezintă rezultate promițătoare pentru clasificarea cancerului pulmonar, evidențiind potențialul său pentru diagnosticul precis al bolii. [\[7\]](#)

Articolul 4 :

În acest articol, sunt folosite date provenite de la șase centre pentru a proiecta un cadru nou de învățare semi-supervizată federată (FSSL) cu agregare dinamică a modelelor și pentru a îmbunătăți performanța segmentării pentru tumori pulmonare. Mai precis, se propune un algoritm actualizat dinamic pentru a gestiona agregarea parametrilor modelului în FSSL, care profită atât de calitatea, cât și de cantitatea datelor clientului. Mai mult, pentru a crește accesibilitatea datelor

în rețeaua de învățare federată (FL), explorează principiul datelor FAIR, în timp ce metodele federate anterioare nu implicau niciodată acest aspect.

Se propune cadru nou de învățare semi-supervizată federată pentru a aborda problemele de confidențialitate a datelor și lipsa datelor adnotate în segmentarea tumorilor pulmonare. Până în prezent, FedDUS(federated semi-supervised learning with dynamic update strategy (= învățare semi-supervizată federată cu strategie dinamică de actualizare)este prima abordare bazată pe învățarea federată și semi-supervizată adaptată pentru segmentarea tumorilor pulmonare.

Luând în considerare dimensiunea, diversitatea și calitatea eșantioanelor de date ale fiecărui client, cadru FedDUS susține agregarea dinamică a modelelor. Cu alte cuvinte, greutatea distribuită unui model local pentru agregarea globală a modelului se schimbă dinamic în fiecare iterație de învățare.

Din câte se știe, acesta este primul articol care utilizează un set de date internațional de amploare mare (2174 de pacienți), inclusiv date publice și private pentru segmentarea tumorilor pulmonare într-o manieră semi-supervizată federată.

Acest articol explorează principiul de date FAIR pentru a crește găsirea, accesibilitatea, interoperabilitatea și reutilizarea datelor în rețeaua FL.

Rezultatele experimentale arată că performanța de segmentare a modelului în cele șase centre este 0.9348, 0.8436, 0.8328, 0.7776, 0.8870 și, respectiv, 0.8460, ceea ce este superior metodelor tradiționale de învățare profundă și metodelor recente de învățare semi-supervizată federată. [\[8\]](#)

Articolul 5:

Se propune o nouă abordare numită Wavelet U-Net++ pentru segmentarea precisă a nodurilor pulmonari. Abordarea combină arhitectura U-Net++ cu pooling-ul wavelet (tehnică utilizată în prelucrarea imaginilor pentru a reduce dimensiunea datelor prin extragerea caracteristicilor relevante și semnificative)pentru a captura atât informațiile de înaltă, cât și cele de joasă frecvență din imagine, permițând o precizie îmbunătățită în segmentare. În mod specific, se folosește transformarea Haar wavelet pentru a reduce rezoluția hărților de caracteristici în encoder, permițând capturarea detaliilor fine din imagine.



UNIVERSITATEA POLITEHNICA BUCUREȘTI
Facultatea de Inginerie Medicală



S-a evaluat abordarea propusă pe setul de date LIDC-IDRI, care constă din 1018 scanări CT cu noduli pulmonari notate. Rezultatele experimentale demonstrează că abordarea depășește mai multe metode de segmentare de ultimă oră, obținând un coeficient mediu Dice de 0.936 și un IoU mediu de 0.878. Mai mult, se arată că pooling-ul wavelet combinat cu pierderea Tversky și CE îmbunătățește capacitatea rețelei de a detecta noduli mici și neregulați, care sunt în mod convențional dificili de segmentat, demonstrând eficacitatea combinării funcțiilor de pierdere. [\[9\]](#)

3. Îmbunătățirea imaginilor

3.1 Modificare neliniară a contrastului folosind funcția putere

În mod normal, calitatea unei imagini este îmbunătățită prin accentuarea contrastului și a clarității. Pentru a se ajunge la o asemenea modificare, se folosește o metodă adaptivă de îmbunătățire a contrastului și a clarității în domeniul spațial, în care este aplicată o funcție modificată de transformări de tip lege putere. Algoritmul controlează claritatea/finetea percepută, artefactele de tip inel (contrastul) și zgomotul, rezultând într-un echilibru bun între vizibilitatea detaliilor și neafectarea artefactelor prin parametri controlați. Accentuarea clarității / finetei și a contrastului se realizează cu o singură funcție prin alegerea corespunzătoare a parametrilor de control. Parametrul de control al clarității poate fi, de asemenea, folosit pentru a netezi imaginea prin luarea valorii negative a parametrului de claritate. Această metodă poate fi aplicată atât imaginilor în tonuri de gri, cât și imaginilor color, asemănătoare corecției gama (GC). În cazul imaginilor color, este aplicată fiecărui canal R, G și B în mod separat. [\[10\]](#)

$$v = T(u) = (L-1) \left(\frac{u}{L-1} \right)^r$$

$r > 0$ parametru de reglaj

[Fig 3.1](#)

3.2 Modificarea neliniară folosind funcția exponențială

Metoda maximizează contrastul în clasa funcțiilor exponențiale și poate fi folosită pentru restaurarea imaginilor supraexpuse și subexpuse. În teste, imaginile bine expuse au fost distorsionate exponențial, iar rezultatul îmbunătățirii contrastului folosind metoda propusă și egalizarea histogrammei sunt comparate. Deși contrastul furnizat de metoda propusă este mai mic, imaginile rezultate sunt mai netede decât în cazul egalizării histogrammei, în plus, rezultatele maximizării contrastului exponențial au o corelație mai mare cu imaginile originale decât

imaginile distorsionate egalizate cu histograma. Prin utilizarea unei funcții exponențiale, se pot evidenția mai bine anumite detalii ale imaginii și se poate îmbunătăți percepția generală a contrastului. De exemplu, zonele cu intensități mai scăzute pot fi luminate mai mult, în timp ce zonele cu intensități mai mari pot fi înnegrite, ceea ce poate duce la o imagine mai echilibrată și mai ușor de interpretat. Utilizarea unei funcții exponențiale oferă flexibilitate în ajustarea contrastului și clarității în funcție de nevoile specifice ale imaginii sau ale aplicației. [\[11\]](#)

3.3 Modificarea neliniara folosind functia logaritmica

Modificarea contrastului folosind funcția logaritmică reprezintă o altă tehnică comună în procesarea imaginilor. Această metodă se bazează pe ideea că valoarea logaritmului natural al unei imagini poate fi utilizată ca măsură a contrastului său. Funcția logaritmică are o formă generală de $c * \log(1 + x)$, unde x reprezintă valoarea pixelului și c este o constantă de scalare ce poate fi ajustată în funcție de necesități. Pentru a mări contrastul, se utilizează o valoare mai mare pentru c , în timp ce pentru a scădea contrastul, se folosește o valoare mai mică pentru c . În cazul creșterii contrastului, valorile pixelilor mai mici decât 1 sunt extinse, în timp ce valorile pixelilor mai mari decât 1 sunt comprimate. Aceasta se datorează faptului că logaritmul natural este mai mare pentru valorile x mai mari decât 1, astfel încât acestea sunt mai afectate decât cele mai mici decât 1. În situația în care se dorește reducerea contrastului, se aplică același principiu, însă în direcția opusă. Valorile pixelilor mai mari decât 1 sunt extinse, iar cele mai mici decât 1 sunt comprimate. Este important de remarcat că funcția logaritmică poate afecta negativ detaliile fine ale imaginii, motiv pentru care trebuie utilizată cu atenție și cu valori adecvate pentru constanta de scalare. De asemenea, este recomandat să se aplice această tehnică pe o copie a imaginii originale pentru a permite comparația rezultatelor și pentru a evita pierderea informațiilor importante din imaginea inițială. [\[12\]](#)

Contributie personala: 3.4 Modificarea contrastului folosind corectia Gamma

Corecția gamma este o tehnică folosită pentru ajustarea luminozității și contrastului imaginilor afișate pe dispozitive electronice. Este deosebit de importantă în imagistica medicală, unde afișarea precisă a imaginilor este esențială pentru diagnostic și tratament. Corecția gamma

este folosită pentru a asigura că imaginile sunt afișate corect pe dispozitiv și arată la fel cum au fost concepute de creator. Pentru a aplica corecția gamma la imaginile medicale, primul pas este să se determine valoarea gamma a dispozitivului de afișare care va fi folosit pentru vizualizarea imaginilor. Odată ce valoarea gamma a dispozitivului de afișare a fost determinată, valorile de intensitate ale imaginilor medicale pot fi ajustate pentru a se potrivi caracteristicilor dispozitivului. [\[13\]](#)

3.4 Segmentarea: Binarizarea

Convertirea unei imagini în tonuri de gri într-o imagine alb-negru, numită și imagine binară, este cunoscută sub numele de binarizare. Cea mai simplă modalitate de binarizare este pragul; stabilirea pixelilor la alb (sau 1) dacă valoarea tonului de gri este egală sau mai mare decât pragul, sau la negru (0) dacă este mai mică. Atunci când se utilizează binarizarea adaptivă, nivelul de prag este determinat automat pe baza conținutului imaginii sau a secvenței de imagini. O metodă alternativă este folosirea unui procentaj dat din histograma intensității ca valoare de prag. În contrast, binarizarea adaptivă local folosește un nivel care variază obiect cu obiect în imagine. Aceasta poate distinge punctele luminoase, formele pe un fundal variabil. Există mai multe metode de binarizare disponibile, inclusiv binarizarea globală și binarizarea locală. Binarizarea globală se bazează pe alegerea unui prag global pentru toată imaginea, ceea ce poate funcționa bine pentru imaginile cu iluminare uniformă. În schimb, binarizarea locală implică utilizarea unor praguri locale pentru regiuni mici ale imaginii, ceea ce poate fi util pentru imagini cu iluminare inegală sau pentru detectarea obiectelor de diferite dimensiuni și forme. [\[14\]](#)

3.5 Contributie personala: Metoda Otsu

O metodă bine stabilită de determinare automată a pragului este metoda lui Otsu. Metoda pragului Otsu este o tehnică utilizată în procesarea imaginilor pentru a determina un prag optim pentru binarizarea automată a imaginilor. Această metodă implică următoarele etape:

1. Iterarea prin toate posibilele valori de prag: Algoritmul începe prin a itera printr-o gamă de valori de prag posibile, care reprezintă toate valorile de intensitate ale pixelilor din imagine.

2. Calcularea măsurii de dispersie: Pentru fiecare valoare de prag, se calculează o măsură a dispersiei nivelurilor de pixeli de fiecare parte a pragului. Această măsură de dispersie poate fi varianța sau deviația standard a intensităților pixelilor din prim-plan și din fundal.

3. Alegerea pragului optim: Scopul este să se aleagă valoarea de prag la care suma măsurilor de dispersie pentru prim-plan și fundal este minimă. Aceasta indică că separarea dintre prim-plan și fundal este maximă la acest prag.

În esență, algoritmul caută acel prag care minimizează variabilitatea dintre nivelurile de pixeli din prim-plan și fundal, ceea ce înseamnă că imaginea va fi binarizată astfel încât să se obțină cel mai clar contrast între aceste două regiuni. Prin urmare, pragul optim este ales pentru a asigura că obiectele de interes din imagine sunt separate eficient de fundal. [\[15\]](#)

Coduri folosite

Modificare neliniara a contrastului folosind functia putere

```
import matplotlib.pyplot as plt

import numpy as np

import os

cale = r'C:\Users\strat\Downloads'

cale_img = os.path.join(cale, 'img1.jpeg')

img = plt.imread(cale_img)

def extindere(img, L, r):

    s = img.shape

    img_out = np.zeros([s[0], s[1], s[2]], dtype='float')

    img = img.astype('float')
```



```
for i in range(0, s[0]):
```

```
    for j in range(0, s[1]):
```

```
        img_out[i, j] = (L - 1) * (img[i, j] / (L - 1)) ** r
```

```
img_out = np.clip(img_out, 0, 255)
```

```
img_out = img_out.astype('uint8')
```

```
return img_out
```

```
img_out = extindere(img, 255, 2)
```

```
plt.figure()
```

```
plt.subplot(1, 2, 1), plt.imshow(img, cmap='gray'), plt.title('Imaginea 1 Originala')
```

```
plt.subplot(1, 2, 2), plt.imshow(img_out, cmap='gray'), plt.title('Imaginea 1 cu Functia putere')
```

```
plt.show()
```

Modificare neliniara folosind functia exponentiala

```
import matplotlib.pyplot as plt
```

```
import numpy as np
```

```
import os
```

```
cale = r'C:\Users\strat\Downloads'
```

```
cale_img = os.path.join(cale, 'img1.jpeg')
```

```
img = plt.imread(cale_img)
```

```
def exponentiala(img, L):
```

```
    s = img.shape
```

```
    img_out = np.zeros([s[0], s[1], s[2]], dtype='float')
```

```
    img = img.astype(float)
```

```
for i in range(0, s[0]):
```

```
    for j in range(0, s[1]):
```

```
        img_out[i, j] = L ** ((img[i, j] / (L - 1)) - 1)
```

```
img_out = np.clip(img_out, 0, 255)
```

```
img_out = img_out.astype('uint8')
```

```
return img_out
```

```
img_out = exponentiala(img, 100)
```

```
plt.figure()
```

```
plt.subplot(1, 2, 1), plt.imshow(img, cmap='gray'), plt.title('Imaginea Originala')
```

```
plt.subplot(1, 2, 2), plt.imshow(img_out, cmap='gray'), plt.title('Imaginea 1 Modificata cu functia  
exponentiala')
```

```
plt.show()
```

Modificarea neliniara folosind functia logaritmica

```
import matplotlib.pyplot as plt
```

```
import numpy as np
```

```
import os
```

```
cale = r'C:\Users\strat\Downloads'
```

```
cale_img = os.path.join(cale, 'img1.jpeg')
```

```
img = plt.imread(cale_img)
```

```
def logaritm(img, L):
```

```
    s = img.shape
```

```
    img_out = np.zeros([s[0], s[1], s[2]], dtype='float')
```

```
    img = img.astype(float)
```

```
for i in range(0, s[0]):  
  
    for j in range(0, s[1]):  
  
        img_out[i, j] = ((L - 1) / np.log(L)) * np.log(img[i, j] + 1)  
  
img_out = np.clip(img_out, 0, 255)  
  
img_out = img_out.astype('uint8')  
  
return img_out  
  
img_out = logaritm(img, 255)  
  
plt.figure()  
  
plt.subplot(1, 2, 1), plt.imshow(img, cmap='gray'), plt.title('Imaginea Originala')  
  
plt.subplot(1, 2, 2), plt.imshow(img_out, cmap='gray'), plt.title('Imaginea 1 cu functia log')  
  
plt.show()
```

Segmentare: Binarizare

```
import numpy as np  
  
import os  
  
import matplotlib.pyplot as plt  
  
cale= r'C:\Users\strat\Downloads'  
  
cale_img=os.path.join(cale, 'img6.jpeg')  
  
img_in=plt.imread(cale_img)  
  
def binarizare(img_in,a,b,Ta,Tb,L_1):  
  
    img_final=np.empty_like(img_in)  
  
    img_in=img_in.astype(float)  
  
    s=img_in.shape
```

```
for i in range(0,s[0]):  
  
    for j in range(0,s[1]):  
  
        if (img_in[i,j]<a).any():  
  
            img_final[i,j]=Ta/a*img_in[i,j]  
  
        elif (img_in[i,j]>a).any() and (img_in[i,j]<b).any():  
  
            img_final[i,j]=Ta+((Tb-Ta)/(b-a))*(img_in[i,j]-a)  
  
        else:  
  
            img_final[i,j]=Tb+((L_1-Tb)/(L_1-b))*(img_in[i,j]-b)  
  
img_final=np.clip(img_final,0,255)  
  
img_final=img_final.astype('uint8')  
  
return img_final  
  
img_final=binarizare(img_in,150,150,0,0,255)  
  
plt.figure()  
  
plt.subplot(1,2,1),plt.imshow(img_in,cmap='gray'),plt.title('Imaginea Originala')  
  
plt.subplot(1,2,2),plt.imshow(img_final,cmap='gray'),plt.title('Imaginea 6 Binarizata')  
  
plt.show()  
  
print('===')
```

Operatiile morfologice: Deschiderea

```
import numpy as np  
  
import os  
  
import matplotlib.pyplot as plt  
  
import scipy.ndimage as sc
```

```
cale = r'C:\Users\strat\Downloads'

cale_img = os.path.join(cale, 'img6.jpeg')

img_init = plt.imread(cale_img)

def rgb2gri(img_in, format):

    img_in = img_in.astype('float')

    s = img_in.shape

    if len(s) == 3 and s[2] == 3:

        if format == 'png':

            img_out = (0.299 * img_in[:, :, 0] + 0.587 * img_in[:, :, 1] + 0.114 * img_in[:, :, 2]) * 255

        elif format == 'jpg':

            img_out = 0.299 * img_in[:, :, 0] + 0.587 * img_in[:, :, 1] + 0.114 * img_in[:, :, 2]

            img_out = np.clip(img_out, 0, 255)

            img_out = img_out.astype('uint8')

            return img_out

    else:

        print('Conversia nu a putut fi realizata deoarece imaginea de intrare nu este color!')

        return img_in

img_init = rgb2gri(img_init, 'jpg')

def binarizare(img_init, a, b, Ta, Tb, L_1):

    img_final = np.empty_like(img_init)

    img_init = img_init.astype(float)
```

```
s = img_init.shape

for i in range(0, s[0]):

    for j in range(0, s[1]):

        if (img_init[i, j] < a).any():

            img_final[i, j] = Ta / a * img_init[i, j]

        elif (img_init[i, j] > a).any() and (img_init[i, j] < b).any():

            img_final[i, j] = Ta + ((Tb - Ta) / (b - a)) * (img_init[i, j] - a)

        else:

            img_final[i, j] = Tb + ((L_1 - Tb) / (L_1 - b)) * (img_init[i, j] - b)

img_final = np.clip(img_final, 0, 255)

img_final = img_final.astype('uint8')

return img_final

v1 = np.array([[1, 1, 1, 1, 1]])

v2 = np.array([[1], [1], [1]])

v3 = np.array([[1, 1, 1], [1, 1, 1], [1, 1, 1]])

v4 = np.array([[0, 1, 0], [1, 1, 1], [0, 1, 0]])

v5 = np.array([[1, 0, 0], [0, 1, 0], [0, 0, 1]])

v6 = np.array([[0, 0, 1], [0, 1, 0], [1, 0, 0]])

y = binarizare(img_init, 150, 150, 0, 0, 255)

deschidere = sc.binary_opening(y, structure=v1)

deschidere2 = sc.binary_opening(y, structure=v2)

deschidere3 = sc.binary_opening(y, structure=v3)
```

```
deschidere4 = sc.binary_opening(y, structure=v4)

deschidere5 = sc.binary_opening(y, structure=v5)

deschidere6 = sc.binary_opening(y, structure=v6)

plt.figure("Total")

plt.subplot(3, 3, 1), plt.imshow(img_init, cmap='gray'), plt.title('imaginea initiala')

plt.subplot(3, 3, 2), plt.imshow(y, cmap='gray'), plt.title('binarizare')

plt.subplot(3, 3, 4), plt.imshow(deschidere, cmap='gray'), plt.title('deschidere1')

plt.subplot(3, 3, 5), plt.imshow(deschidere2, cmap='gray'), plt.title('deschidere2')

plt.subplot(3, 3, 6), plt.imshow(deschidere3, cmap='gray'), plt.title('deschidere3')

plt.subplot(3, 3, 7), plt.imshow(deschidere4, cmap='gray'), plt.title('deschidere4')

plt.subplot(3, 3, 8), plt.imshow(deschidere5, cmap='gray'), plt.title('deschidere5')

plt.subplot(3, 3, 9), plt.imshow(deschidere6, cmap='gray'), plt.title('deschidere6')

plt.show()
```

Operatii morfologice: Inchiderea

```
import numpy as np

import os

import matplotlib.pyplot as plt

import scipy.ndimage as sc

cale = r'C:\Users\strat\Downloads'

cale_img = os.path.join(cale, 'img6.jpeg')

img_init = plt.imread(cale_img)
```

```
def rgb2gri(img_in, format):

    img_in = img_in.astype('float')

    s = img_in.shape

    if len(s) == 3 and s[2] == 3:

        if format == 'png':

            img_out = (0.299 * img_in[:, :, 0] + 0.587 * img_in[:, :, 1] + 0.114 * img_in[:, :, 2]) * 255

        elif format == 'jpg':

            img_out = 0.299 * img_in[:, :, 0] + 0.587 * img_in[:, :, 1] + 0.114 * img_in[:, :, 2]

            img_out = np.clip(img_out, 0, 255)

            img_out = img_out.astype('uint8')

            return img_out

    else:

        print('Conversia nu a putut fi realizata deoarece imaginea de intrare nu este color!')

        return img_in

img_init = rgb2gri(img_init, 'jpg')

def binarizare(img_init, a, b, Ta, Tb, L_1):

    img_final = np.empty_like(img_init)

    img_init = img_init.astype(float)

    s = img_init.shape

    for i in range(0, s[0]):

        for j in range(0, s[1]):

            if (img_init[i, j] < a).any():
```



```
img_final[i, j] = Ta / a * img_init[i, j]

elif (img_init[i, j] > a).any() and (img_init[i, j] < b).any():

    img_final[i, j] = Ta + ((Tb - Ta) / (b - a)) * (img_init[i, j] - a)

else:

    img_final[i, j] = Tb + ((L_1 - Tb) / (L_1 - b)) * (img_init[i, j] - b)

img_final = np.clip(img_final, 0, 255)

img_final = img_final.astype('uint8')

return img_final

v1 = np.array([[1, 1, 1, 1, 1]])

v2 = np.array([[1], [1], [1]])

v3 = np.array([[1, 1, 1], [1, 1, 1], [1, 1, 1]])

v4 = np.array([[0, 1, 0], [1, 1, 1], [0, 1, 0]])

v5 = np.array([[1, 0, 0], [0, 1, 0], [0, 0, 1]])

v6 = np.array([[0, 0, 1], [0, 1, 0], [1, 0, 0]])

y = binarizare(img_init, 120, 120, 0, 255, 255)

inchidere1 = sc.binary_closing(y, structure=v1)

inchidere2 = sc.binary_closing(y, structure=v2)

inchidere3 = sc.binary_closing(y, structure=v3)

inchidere4 = sc.binary_closing(y, structure=v4)

inchidere5 = sc.binary_closing(y, structure=v5)

inchidere6 = sc.binary_closing(y, structure=v6)
```

```
plt.figure('Total')

plt.subplot(3, 3, 1), plt.imshow(img_init, cmap='gray'), plt.title('imaginea initiala')

plt.subplot(3, 3, 3), plt.imshow(y, cmap='gray'), plt.title('binarizare')

plt.subplot(3, 3, 4), plt.imshow(inchidere1, cmap='gray'), plt.title('inchidere1')

plt.subplot(3, 3, 5), plt.imshow(inchidere2, cmap='gray'), plt.title('inchidere2')


plt.subplot(3, 3, 6), plt.imshow(inchidere3, cmap='gray'), plt.title('inchidere3')

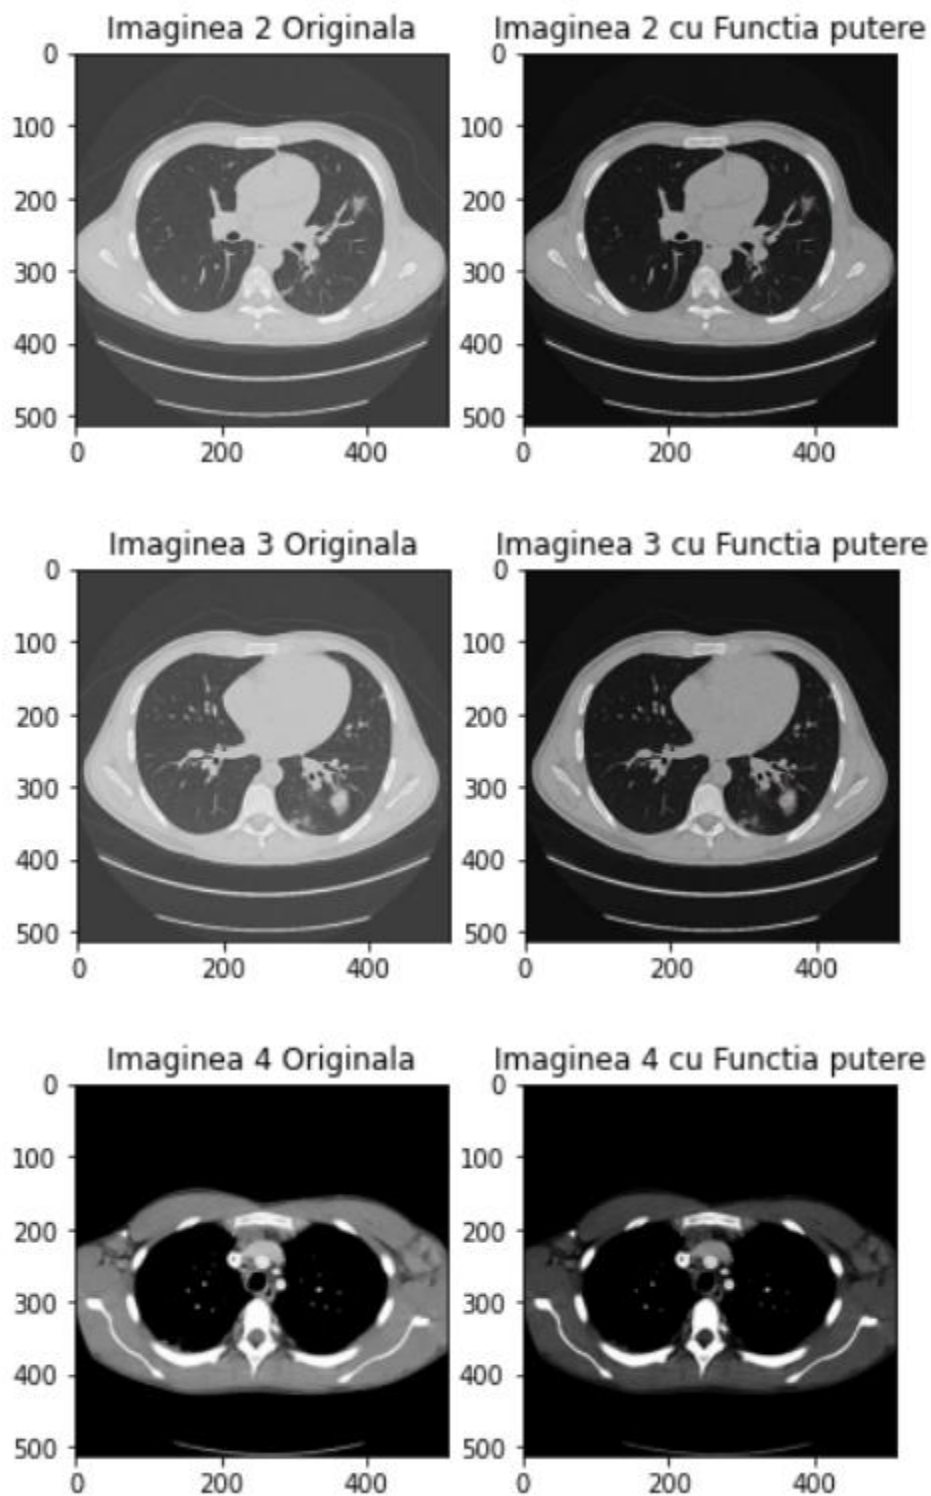
plt.subplot(3, 3, 7), plt.imshow(inchidere4, cmap='gray'), plt.title('inchidere4')

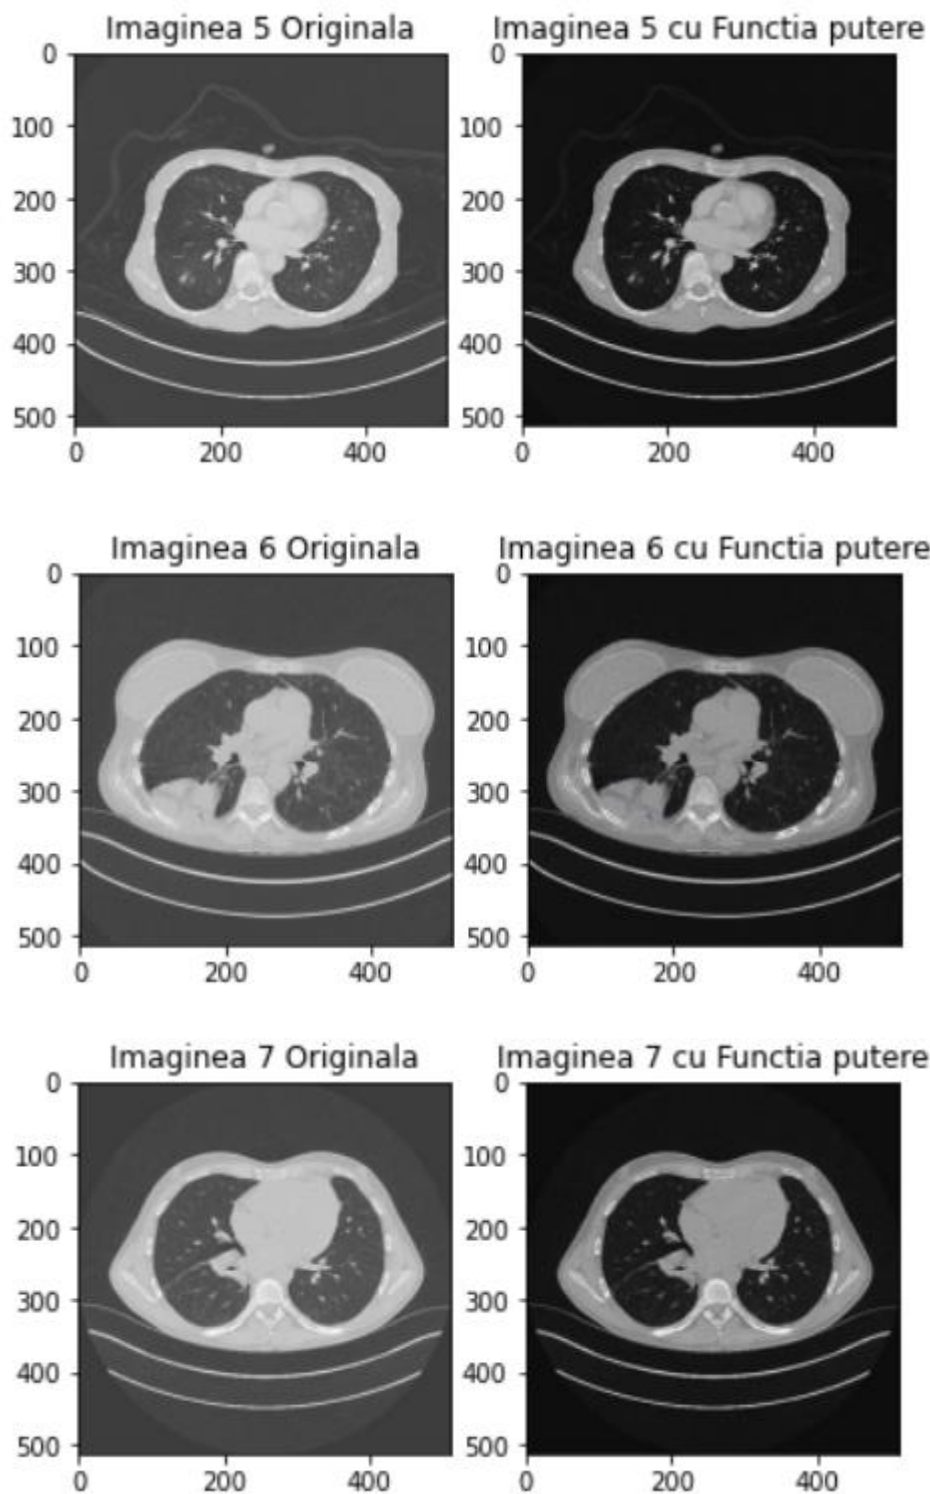
plt.subplot(3, 3, 8), plt.imshow(inchidere5, cmap='gray'), plt.title('inchidere5')

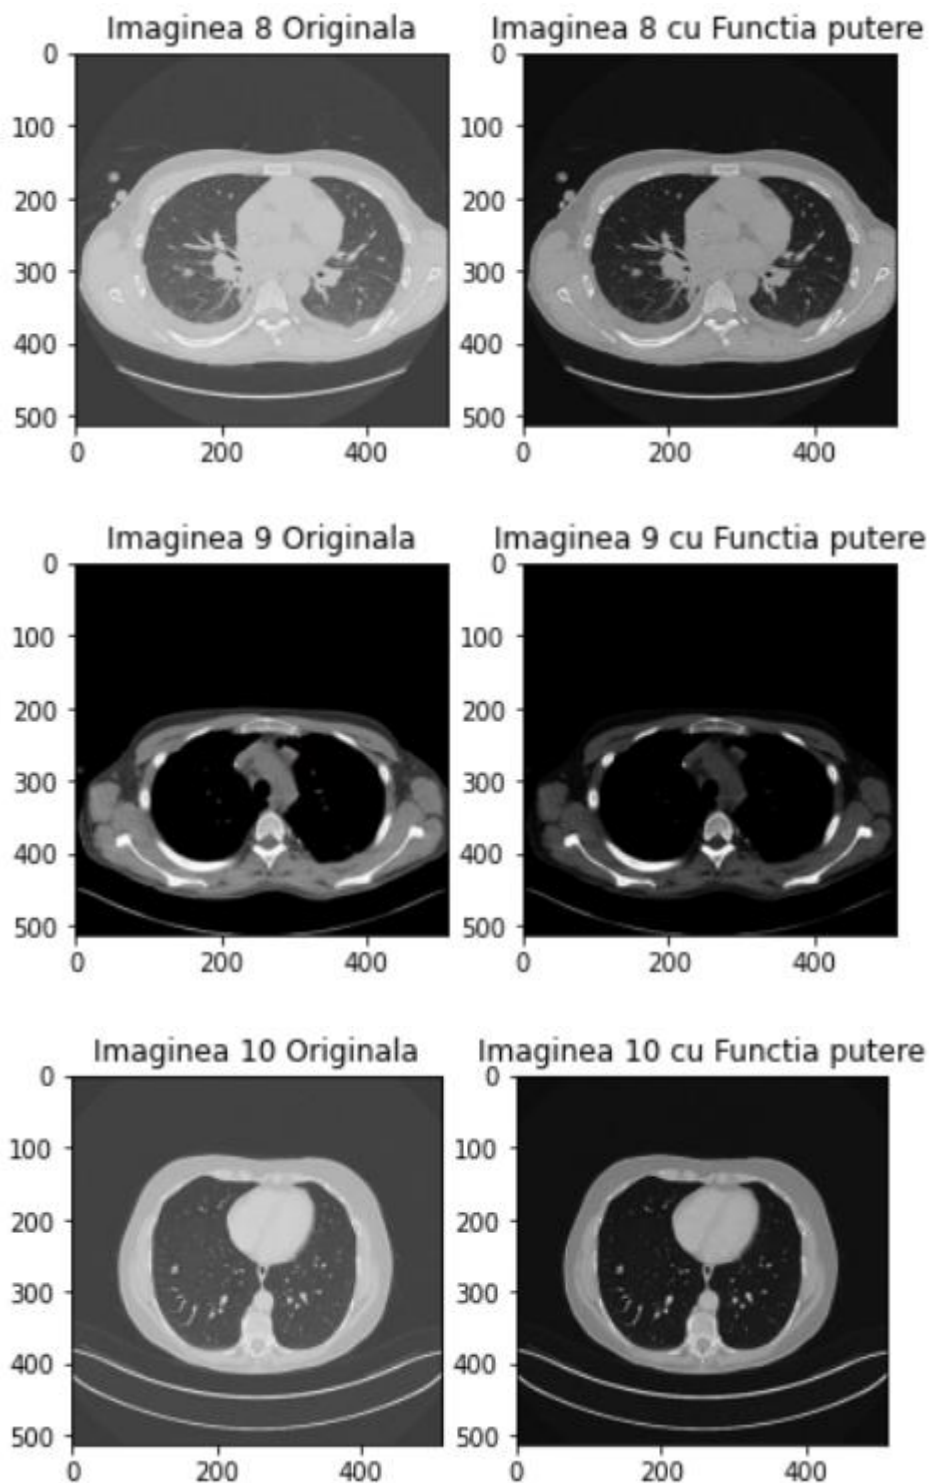
plt.subplot(3, 3, 9), plt.imshow(inchidere6, cmap='gray'), plt.title('inchidere6')




plt.show()
```
















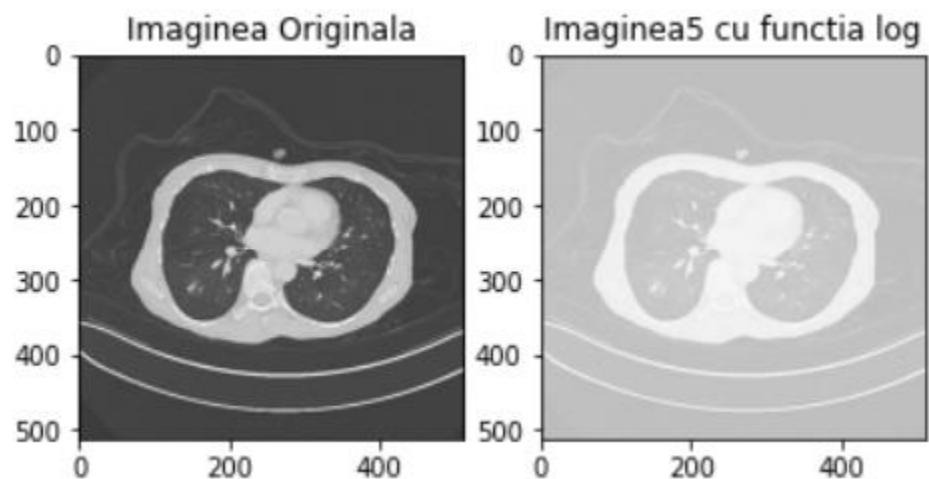




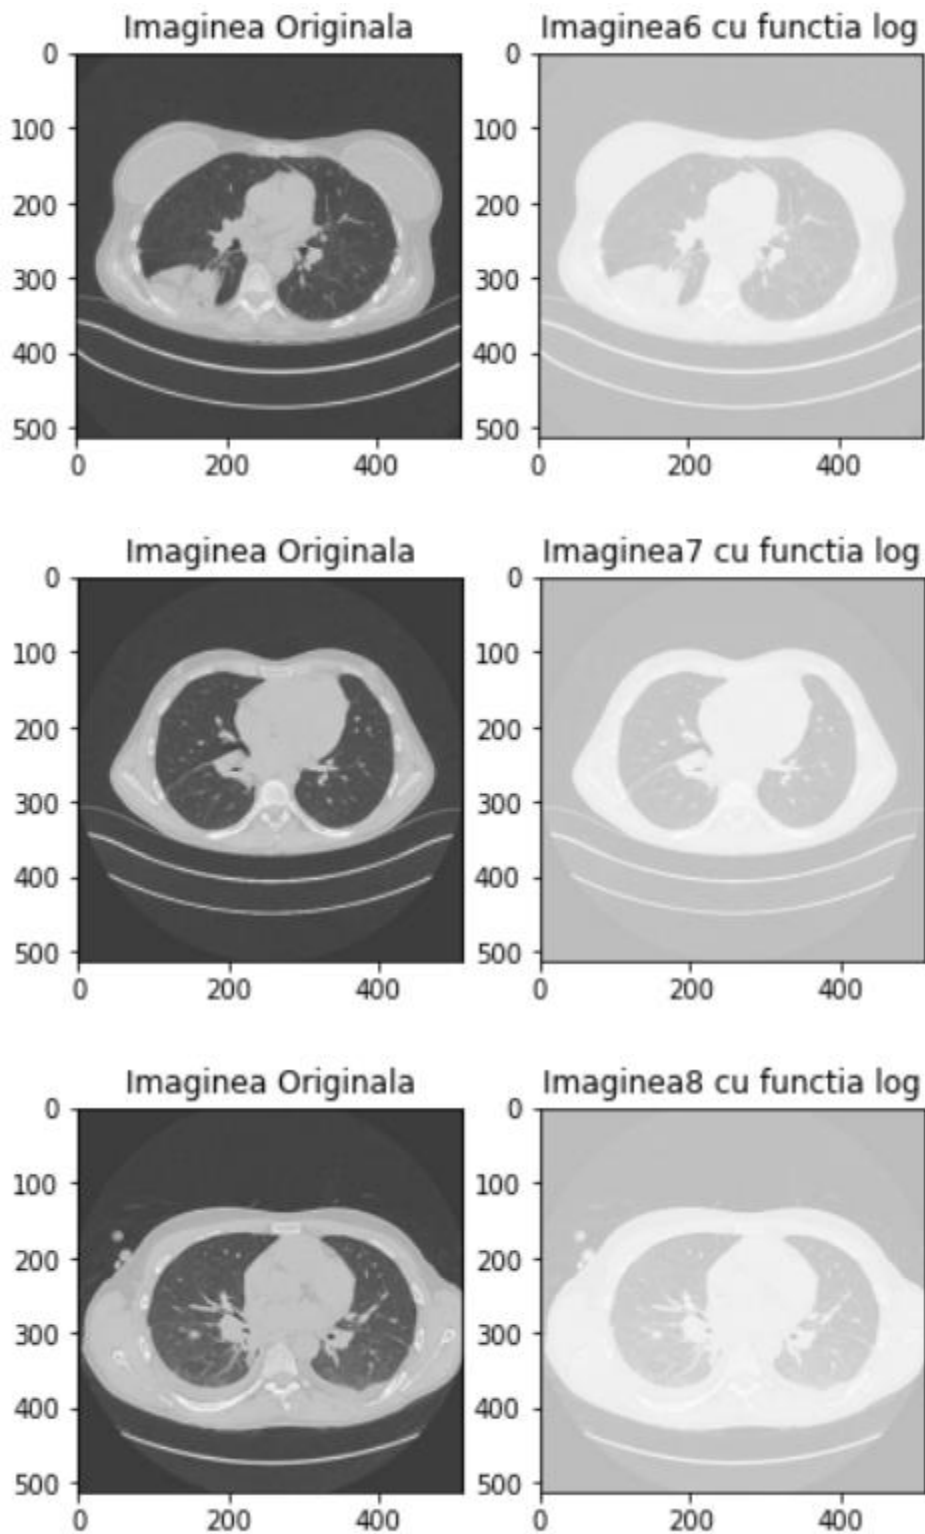

















Imaginea castigatoare este imaginea 6 deoarece tumora este evidenta, indiferent de operatiile aplicate. Astfel, pe aceasta se va face operatia de segmentare, anume binarizarea, pentru a se accentua afectiunea studiata.




In imaginea binarizata, tumoarea este bine definita, clara si usor de observat. Vom alege deschiderea, care este o tehnica utilizata in prelucrarea imaginilor pentru a evidentia si a accentua anumite caracteristici sau detalii. Aceasta presupune dilatarea sau extinderea regiunilor luminoase (zonele albe) ale unei imagini si reducerea sau subtierea regiunilor întunecate (zonele negre). Astfel, aceasta operatie morfologica este necesara in cazul imaginii noastre, pentru eliminarea detaliilor nedorite si îmbunatatirea claritatii si vizibilitatii imaginii.

Dupa aplicarea operatiei de deschidere, s-a obtinut:



Deschiderea ca operatie morfologica este o tehnica utilizata in prelucrarea imaginilor pentru a evidentia si a accentua anumite caracteristici sau detalii. Aceasta operatie presupune dilatarea sau extinderea regiunilor luminoase (zonele albe) ale unei imagini si reducerea sau subtierea regiunilor întunecate (zonele negre). Este utila în eliminarea zgomotului sau a detaliilor nedorite si poate îmbunatti claritatea si vizibilitatea imaginii.


Dupa aplicarea operatiei morologice de inchidere, s-a obtinut :



Închiderea este o operație morfologică utilizată în prelucrarea imaginilor pentru a elimina mici discontinuități în obiecte și pentru a conecta obiectele apropiate. Aceasta constă într-o eroziune urmată de o dilatare a imaginii. Procesul începe cu o eroziune, care constă în "ștergerea" sau "subțierea" marginilor obiectelor din imagine. Acest lucru elimină detalii fine și micșorează dimensiunea obiectelor. Apoi, este aplicată o dilatare, care constă în "umplerea" sau "extinderea" marginilor obiectelor. Acest lucru are ca rezultat umplerea găurilor mici și conectarea obiectelor care sunt apropiate una de cealaltă. Închiderea este utilă în procesul de eliminare a zgomotului și a detaliilor nedorite din imagine, precum și în îmbunătățirea continuității și a formei obiectelor.


4. Rezultate obtinute

Dupa modificarea contrastului cu functia putere s-a obtinut urmatoarea imagine :



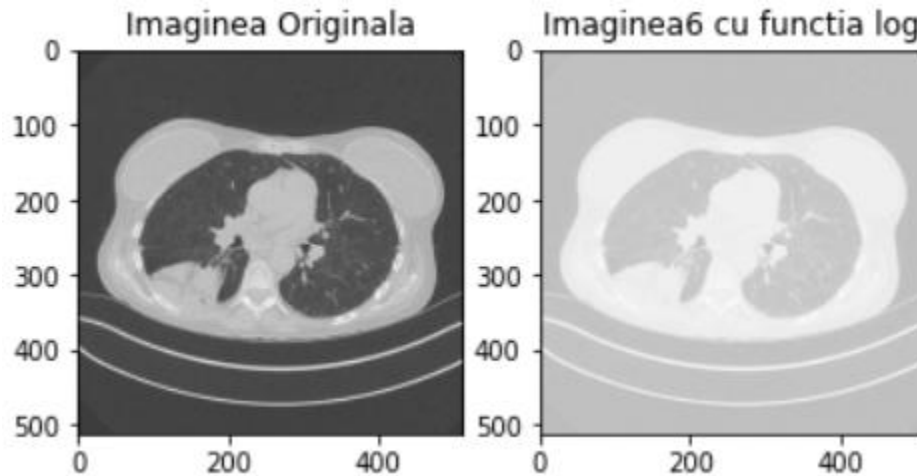
Am luat parametrul de reglaj $r=2$ pentru a obtine o imagine mai intunecata, unde sa se accentueze afectiunea. Detectia a fost reusita.

Dupa modificarea contrastului cu functia exponentiala s-a obtinut urmatoarea imagine :




Zonele cu intensitati mai scazute sunt luminate mai mult, in timp ce zonele cu intensitati mai mari sunt innegrite si mai usor de interpretat, imaginea finala fiind mai neteda. Detectia a fost reusita.

Dupa modificarea contrastului cu functia logaritmica s-a obtinut urmatoarea imagine :



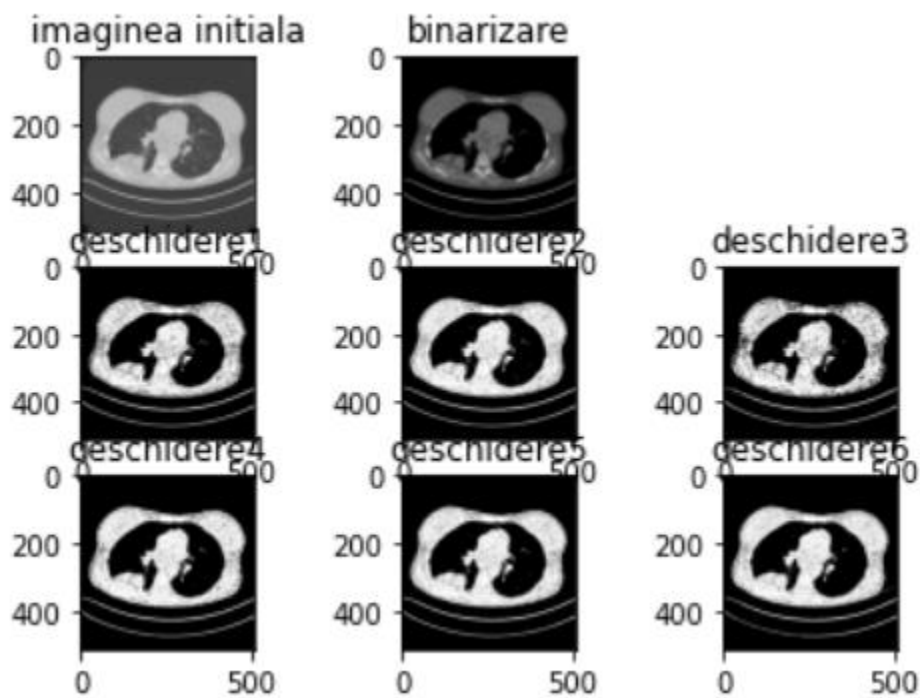
Parametrul u este egal cu 0, astfel incat scade contrastul si valorile pixelilor sunt comprimate, iar imaginea finala este neclara, distorsionata. Detectia a fost nereusita.

Dupa aplicarea operatiei de binarizare, s-a obtinut urmatoarea imagine :



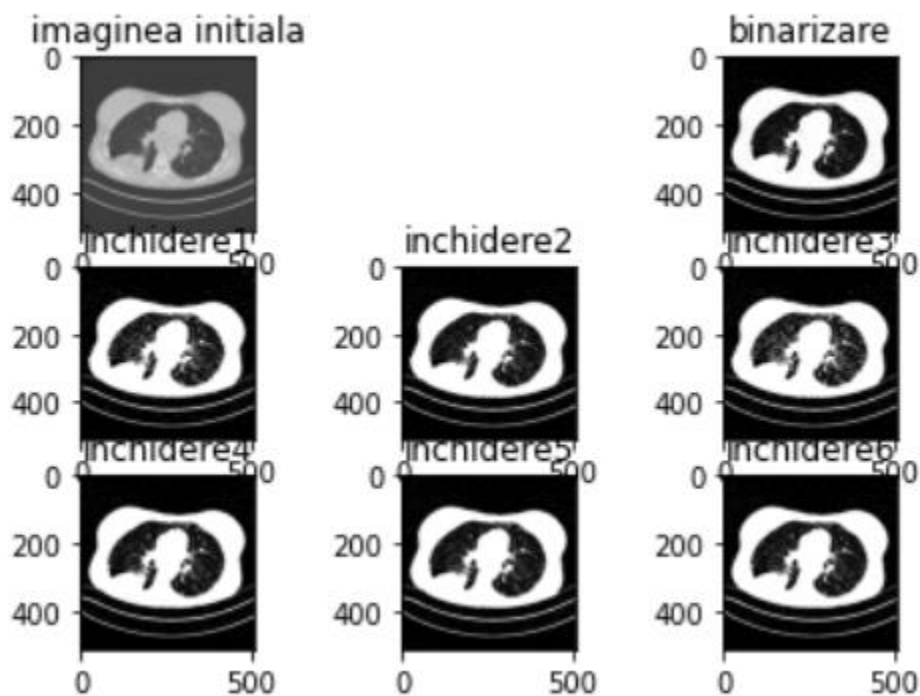
Am pus parametrii $a=b=150$, $T_a=0$ si $T_b=255$. Această transformare se bazează pe alegerea unui prag de valoare. Pixelii mai deschiși decât pragul ales (150) sunt transformați în alb, iar restul în negru. Astfel se va obtine o imagine clara, in care afectiunea este bine conturata si usor de observat.

Dupa aplicarea operatiei de deschidere, s-a obtinut:



Operatia de deschidere face marginile imaginii mai clare si mai definite, eliminand elementele mici, vasele de sange, din imaginea initiala. Imaginea devine mai lumioasa, zona de interes este mai accentuata, afectiunea fiind usor de observat.

Dupa aplicarea operatiei morologice de inchidere, s-a obtinut :



In imaginile obtinute prin inchidere se observa vasele de sange ale plamanilor, iar tumoarea se observa, insa nu este conturata corespunzator.

Concluzii

Aplicand modificarile de contrast cu functiile : logaritmica, putere, exponentiala, in unele imagini afectiunea a fost mai bine accentuata, iar in altele mai putin evidenta. Dupa aplicarea acestor functii, s-a observat ca imaginea 6 este cea mai relevanta deoarece tumoarea a putut fi observata cu usurinta, indiferent de operatiile la care a fost supusa.

Cea mai relevanta metoda de imbunatatire a calitatii imaginii este metoda de modificare a contrastului cu functia exponentiala deoarece tumora este mai bine definita fata de imaginea initiala.

Metoda de segmentare optima este binarizarea deoarece sunt eliminate vasele de sange din imaginea initiala, se contureaza imaginea si tumoarea este astfel mai accentuata.

Operatia morfologica de inchidere nu a fost la fel de precisa precum cea de deschidere deoarece afectiunea nu a fost bine conturata pe margini si nu a fost la fel de usor de observat cu ochiul liber. Astfel, operatia morfologica aleasa a fost deschiderea datorita faptului ca a conturat foarte bine marginile imaginii si patologiei, a rezultat o imagine mai luminoasa si mai usor de interpretat.

Exceptand aplicarea modificarii contrastului cu functia logaritmica, celelalte metode au generat rezultate satisfacatoare, utile in determinarea unui diagnostic. In cazul imaginilor mai intunecate, functia logaritmica a fost utila, iar in cazul imaginilor cu mai multe tonuri de gri aceasta functie a distorsionat imaginea si a facut-o prea luminoasa, fiind greu de detectat afectiunea.

Aplicarea binarizarii si deschiderii a generat imagini clare, bine conturate, usor de evidentiati patologia.

Prin modificarea anumitor parametrii precum r (parametru de reglaj), a, b (parametrii de prag), imaginile pot fi fie mai intunecate, fie mai deschise, acest lucru stabilindu-se in functie de imaginea initiala.

Bibliografie

https://ro.wikipedia.org/wiki/Cancer_pulmonar

<https://www.reginamaria.ro/utile/dictionar-de-afectiuni/cancer-bronho-pulmonar>

https://en.wikipedia.org/wiki/CT_scan

<https://www.medlife.ro/articole-medicale/tomografia-computerizata-ct-cum-functioneaza-cand-se-utilizeaza-avantaje-riscuri>

Articolul 1 : [https://www.cell.com/iscience/pdf/S2589-0042\(22\)01985-X.pdf](https://www.cell.com/iscience/pdf/S2589-0042(22)01985-X.pdf)

Articolul 2 : <https://www.mdpi.com/2306-5354/10/8/981>

Articolul 3 : <https://www.sciencedirect.com/science/article/abs/pii/S1746809422004852>

Articolul 4 :

<https://www.sciencedirect.com/science/article/abs/pii/S0169260724001378?via%3Dihub>

Articolul 5 : <https://www.sciencedirect.com/science/article/abs/pii/S1746809423009424>

https://www.researchgate.net/profile/Thounaojam-Singh/publication/281579136_Image_Enhancement_by_Adaptive_Power-Law_Transformations/links/55f16d0208ae0af8ee1d6556/Image-Enhancement-by-Adaptive-Power-Law-Transformations.pdf?origin=publication_detail&tp=eyJjb250ZXh0Ijp7ImZpcnN0UGFnZSI6Ii9kaXJlY3QiLCJwYWdlIjoicHVibGljYXRpb25Eb3dubG9hZCIsInByZXZpb3VzUGFnZSI6Ii9kaXJlY3QmY2F0aW9uIn19

Lab 4 TSIM

https://www.researchgate.net/profile/Andras-Hajdu/publication/233731162_Exponential_contrast_maximization_of_intensity_images/links/53ff1b8e0cf283c3583c7ed4/Exponential-contrast-maximization-of-intensity-images.pdf?origin=publication_detail&tp=eyJjb250ZXh0Ijp7ImZpcnN0UGFnZSI6Ii9kaXJlY3QmY2F0aW9uIn19



UNIVERSITATEA POLITEHNICA BUCUREȘTI
Facultatea de Inginerie Medicală



[QiLCJwYWdlIjoicHVibGljYXRpb25Eb3dubG9hZCIsInByZXZpb3VzUGFnZSI6InB1YmxpY2F0aW9uIn19](#)

<https://dl.icdst.org/pdfs/files4/01c56e081202b62bd7d3b4f8545775fb.pdf>

<https://levelup.gitconnected.com/contrast-enhancement-techniques-for-medical-images-93c805fce01c>

http://help.imageanalyst.net/ImageProcessingBasics_Binarization.html

https://www.researchgate.net/profile/Sunil-Bangare-2/publication/282282124_Reviewing_Otsu's_Method_For_Image_Thresholding/links/57c6e3e408ae9d64047e90dc/Reviewing-Otsus-Method-For-Image-Thresholding.pdf